

Capítulo 1: Fundamentos del Aprendizaje Automático

Material del curso

Universidad de Salamanca

Facultades de Ciencias y Ciencias Químicas

24 de septiembre de 2026

❶ 1.1 Historia y evolución del aprendizaje automático

- De los mínimos cuadrados (1805) a la IA Generativa
- Los “inviernos de la IA” y por qué ocurrieron

❷ 1.2 Conceptos fundamentales

- Datos, *features* y etiquetas
- *Overfitting*, validación cruzada y métricas
- El *pipeline* de ML de principio a fin

Estos fundamentos son la base para todo lo que viene después: sin ellos, es difícil entender por qué un modelo funciona o falla.

¿Por qué aprender aprendizaje automático?

- En programación **tradicional**, un humano escribe todas las reglas a mano:
 - si temperatura > 30: encender_aire_acondicionado()
- Pero muchos problemas son demasiado complejos para reglas fijas
- El **aprendizaje automático invierte el paradigma**: en vez de escribir las reglas, se le enseña a la máquina a *aprender* las reglas a partir de ejemplos

Ejemplo: nadie puede escribir a mano una regla que distinga un gato de un perro en una foto, pero un modelo puede *aprenderla* viendo miles de fotos ya etiquetadas.

El nuevo paradigma de programación

- Para que una máquina aprenda hacen falta **tres elementos**:
 - 1 Datos de entrada
 - 2 Ejemplos de la salida esperada (**etiquetas**)
 - 3 Una forma de medir si lo está haciendo bien (**función de pérdida**)
- La IA no es un concepto nuevo: convive con la IA simbólica (reglas lógicas escritas a mano), que dominó el campo entre los años 50 y finales de los 80

Raíces matemáticas y el Test de Turing (1805-1950)

- 1805: Legendre y Gauss publican los **mínimos cuadrados** — la forma más temprana de regresión lineal
- 1936: Fisher propone el análisis discriminante lineal
- 1943: McCulloch y Pitts presentan el primer modelo de neurona artificial
- 1950: Alan Turing publica "*Computing Machinery and Intelligence*" e introduce el **Test de Turing**



Fuente: Elliott & Fry (1951), dominio público


El nacimiento formal y la era simbólica (1956-1980)

- 1956: John McCarthy organiza el **seminario de Dartmouth** — nace formalmente la IA como campo de investigación
- Durante décadas se creyó que bastaría con codificar a mano un conjunto masivo de reglas lógicas (**IA simbólica**)
- Este enfoque alcanzó su auge con los **sistemas expertos** en los años 80

Ejemplo: un sistema experto médico de los años 80 contenía miles de reglas del tipo “si fiebre y tos y dolor de pecho, entonces sospechar neumonía”, escritas a mano por médicos.

El Perceptrón y los inviernos de la IA


- 1958: Frank Rosenblatt crea el **Perceptrón**, el primer modelo entrenable de neurona artificial
- **Primer invierno** (años 70): el Perceptrón no puede resolver problemas no lineales; el entusiasmo se desploma
- **Segundo invierno** (años 90): los sistemas expertos resultan caros de mantener, difíciles de escalar y limitados
- El ML despegue de verdad en los 90, gracias a hardware más rápido y más datos disponibles



Fuente: Heinz Nixdorf MuseumsForum,


Línea temporal completa

Ciclos de “verano” (avances, financiación) e “invierno” (desilusión, recortes de fondos).



Del *Deep Learning* a la era de los LLM (2010-hoy)

- El **Aprendizaje Profundo** (*Deep Learning*) aprende representaciones en capas sucesivas, cada vez más útiles para la tarea
- 2012: la victoria de Hinton en el desafío **ImageNet** marca el punto de inflexión
- **MNIST** (dígitos manuscritos 0-9) se convierte en el banco de pruebas clásico
- 2017: la arquitectura **Transformer** revoluciona el procesamiento de lenguaje natural
- 2020s: la **IA Generativa** (ChatGPT, Gemini) escala a miles de millones de parámetros



Fuente: Suvanjanprasai (2024), Wikimedia Commons, CC BY-SA 4.0

Resumen: 1.1 Historia y evolución

- El ML nació de una pregunta: ¿pueden las máquinas aprender?
- Ha pasado por ciclos de entusiasmo (*hype*) y desencanto
- Los avances recientes vienen de más datos, mejor hardware y algoritmos nuevos
- El *Deep Learning* y los LLM son el estado del arte actual

Datos, *features* y etiquetas

Muestra	Feature 1	Feature 2	Feature 3	Label
1	25	70	175	Gato
2	8	4	90	Gato
3	35	80	180	Perro


- **Muestra:** un punto de datos individual (una fila de la tabla)
- **Features:** los atributos que describen la muestra
- **Etiqueta:** lo que queremos predecir — la “verdad fundamental”

Ejemplo: para predecir el precio de una vivienda, las *features* serían m², número de habitaciones y ubicación; la etiqueta sería el precio.

Overfitting vs. underfitting


- **Underfitting** (alto sesgo): el modelo es demasiado simple, no capta el patrón real
- **Overfitting** (alta varianza): el modelo memoriza el ruido de entrenamiento en vez de aprender la tendencia
- El objetivo es el equilibrio sesgo-varianza que mejor generaliza a datos nuevos

Ejemplo: es como estudiar para un examen memorizando las respuestas exactas de un simulacro (*overfitting*) en vez de entender el tema: fallarás en cuanto cambien las preguntas.



Validación cruzada *K-fold*

- División estándar: **entrenamiento** (ajustar pesos), **validación** (elegir hiperparámetros) y **prueba** (evaluación final imparcial)
- *K-fold*: se divide en K partes; se entrena K veces usando cada vez una parte distinta como validación
- La métrica final es la media de los K resultados — reduce la varianza de la estimación
- **Estratificación**: cada partición debe conservar la proporción de clases del conjunto original



Matriz de confusión y métricas

Matriz de confusión

		Predicción	
		Positivo	Negativo
Clase real	Positivo	TP Verdadero Positivo	FN Falso Negativo
	Negativo	FP Falso Positivo	TN Verdadero Negativo

$$\text{Precisión} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$F1 = 2 \cdot \frac{P \times R}{P + R}$$

Ejemplo: en un diagnóstico médico, un **falso negativo** (decir “sano” a un paciente enfermo) suele ser más grave que un falso positivo. Por eso a veces se prioriza el *recall* sobre la precisión.

El *pipeline* de ML: 10 etapas

- Proceso **iterativo**: la evaluación puede obligar a volver a etapas anteriores
- Gran parte del esfuerzo real está en las etapas 2-3 (datos) y 7-8 (ajuste)
- El despliegue no es el final: requiere monitorización continua, porque los datos reales cambian con el tiempo (*concept drift*)



- **Muestra / *feature* / etiqueta**: las piezas básicas de cualquier dataset
- ***Overfitting* / *underfitting***: la tensión central del aprendizaje automático
- **Validación cruzada**: evaluar sin sesgo cuando los datos escasean
- **Métricas**: elegir la adecuada según lo que importe (precisión o *recall*)
- ***Pipeline* de ML**: 10 etapas, de la recolección de datos al despliegue

Fin del Capítulo 1

Siguiente: Capítulo 2 — Aprendizaje Supervisado