

Capítulo 3: Aprendizaje No Supervisado

Material del curso

Universidad de Salamanca

Facultades de Ciencias y Ciencias Químicas

24 de septiembre de 2026

- ❶ 3.1 **Clustering**: agrupar datos sin etiquetas
- ❷ 3.2 **Reducción de dimensionalidad**: simplificar y visualizar datos complejos
- ❸ 3.3 **Detección de anomalías**: identificar casos raros o sospechosos

¿Qué es el aprendizaje no supervisado?

- No hay etiquetas: solo tenemos datos de entrada X , sin respuestas correctas y
- El sistema debe descubrir por sí mismo la **estructura latente** de los datos
- Frase de Yann LeCun: *“Si la inteligencia fuera un pastel, el aprendizaje no supervisado sería el bizcocho, el supervisado el glaseado, y el refuerzo la cereza”*

Ejemplo: la inmensa mayoría de los datos del mundo real no vienen etiquetados: fotos, textos, transacciones... por eso este paradigma es tan importante en la práctica.


- **Segmentación de mercado:** agrupar clientes en nichos homogéneos sin definir las categorías de antemano
- **Visualización:** proyectar datos de cientos de variables a 2D o 3D para entenderlos de un vistazo
- **Sistemas de recomendación:** agrupar usuarios o productos con gustos afines
- **Detección de anomalías:** identificar fraudes o fallos de fabricación sin haberlos visto antes

¿Qué es el *clustering*?

- Objetivo: dividir los datos en subgrupos con **alta similitud interna** y **alta diferenciación externa**
- No hay “verdad fundamental”: el sistema debe descubrir la estructura por sí solo
- Algoritmos principales: *K-means*, jerárquico, DBSCAN


K-means: el ciclo del algoritmo

- 1 **Inicialización**: se eligen K centroides
- 2 **Asignación**: cada muestra se une al centroide más cercano
- 3 **Actualización**: cada centroide se recalcula como la media de su grupo
- 4 Se repite hasta que los centroides dejan de moverse (**convergencia**)



K-means: proceso visual


Proceso iterativo de K-means



Ejemplo: es como asignar mesas en una fiesta: cada invitado se sienta en la mesa más cercana, luego cada mesa se recoloca al centro de sus invitados, y se repite hasta que nadie se mueve.


K-means++ y el método del codo

- *K-means* es sensible a la inicialización: centroides mal colocados pueden llevar a un resultado subóptimo
- *K-means++*: elige los centroides iniciales lo más alejados posible entre sí, acelerando la convergencia
- ¿Cuántos grupos *K* elegir? El **método del codo**: se busca el punto donde la inercia deja de caer bruscamente




Clustering jerárquico

- No requiere fijar K de antemano
- Enfoque **aglomerativo** (de abajo a arriba): cada punto empieza siendo su propio grupo, y en cada paso se fusionan los dos más cercanos
- El resultado se visualiza en un **dendrograma**; cortarlo a una altura determina el número final de grupos




Criterios de enlace (*linkage*)

- Definen cómo medir la distancia entre dos grupos, no entre dos puntos
- **Completo**: distancia *máxima* entre miembros — grupos compactos y balanceados
- **Simple**: distancia *mínima* — sensible al ruido, tiende a encadenar grupos alargados
- **Promedio**: media de todas las distancias — equilibrio entre los dos anteriores



DBSCAN: agrupamiento por densidad


- Define los grupos según la **densidad local**, no por cercanía a un centroide
- Dos parámetros: ϵ (radio de vecindad) y **MinPts** (mínimo de vecinos para ser denso)
- Tres tipos de punto: **núcleo** (denso), **frontera** (cerca de un núcleo) y **ruido** (aislado)



DBSCAN vs. *K-means*


- DBSCAN detecta **formas arbitrarias** (no solo esféricas) y aísla el ruido de forma nativa
- *K-means* fuerza a cada punto a pertenecer a un grupo, incluso si es un valor atípico

K-means frente a DBSCAN en datos con forma de luna



Evaluación: coeficiente de silueta


- Sin etiquetas, ¿cómo sabemos si un *clustering* es bueno?
- El coeficiente de silueta compara, para cada punto, su **cohesión** (distancia a su propio grupo) con su **separación** (distancia al grupo más cercano)
- Rango $[-1, 1]$: cerca de $+1$ es un buen agrupamiento; cerca de 0 , frontera ambigua; negativo, mal asignado
- Otros criterios existen (AIC/BIC, pureza, índice Rand...) para comparar frente a etiquetas ya conocidas



- ***K-means***: simple y rápido, pero necesita K conocido y grupos aproximadamente esféricos
- **Jerárquico**: no necesita K , ofrece un dendrograma visual e interpretable
- **DBSCAN**: detecta formas arbitrarias y aísla el ruido automáticamente
- **Silueta**: métrica estándar para evaluar la calidad sin etiquetas

La maldición de la dimensionalidad



- A medida que aumentan las dimensiones, el espacio se vuelve **ultra-disperso**
- Las muestras tienden a situarse en la frontera del espacio, no en el centro
- Las distancias entre puntos se vuelven casi indistinguibles, degradando algoritmos basados en distancia (como K -NN)



¿Por qué reducir dimensiones?


- Acelera drásticamente la computación
- Mitiga el *overfitting*
- Es indispensable para **visualizar** datos complejos en 2D o 3D

La maldición de la dimensionalidad, cuantificada




PCA: la dirección de máxima varianza

- PCA proyecta los datos sobre los ejes donde **más varían**, perdiendo la menor información posible
- PC1: la dirección de máxima varianza; PC2: ortogonal a PC1, captura la varianza restante




PCA: componentes principales

- Se calcula mediante la descomposición en valores singulares (SVD) de la matriz de datos
- Puede verse como un **autoencoder lineal**: comprime y luego reconstruye, minimizando el error



PCA en datos reales: NCI60 (6830 genes)

De 6830 genes a solo 3 componentes principales: las líneas del mismo tipo de cáncer (mismo color) se agrupan a pesar de la enorme dimensionalidad original.




Fuente: James, Witten, Hastie & Tibshirani (2013), An Introduction to Statistical Learning, Fig. 10.15.

Manifold learning: cuando los datos no son planos


- PCA asume que la estructura interesante es **lineal** — falla en estructuras curvas
- La **hipótesis de la variedad**: los datos reales (imágenes, voces...) viven en una superficie de baja dimensión curvada dentro de un espacio de alta dimensión

Swiss roll: motivación del manifold learning

Datos originales (3D)





Variedad desenrollada (2D)



Kernel PCA: el truco del *kernel*

- Mapea los datos a un espacio de más dimensiones donde sí son separables linealmente
- Útil cuando los datos originales no son separables por una línea recta

El truco del kernel: separar lo inseparable




t -SNE: preservar vecindades locales


- Convierte distancias en probabilidades de vecindad: puntos cercanos deben seguir cerca tras la proyección
- Excelente para **visualización** de *clusters* complejos en 2D; más lento en datasets grandes

PCA vs. t-SNE: dos lunas entrelazadas embebidas en 30D

PCA (proyección lineal)
no logra separar las clases




t-SNE (proyección no lineal)
separa cada luna en un grupo



UMAP: rápido y preciso

- Preserva tanto la estructura **local** como la **global**, a diferencia de t -SNE
- Mucho más rápido: apto para datasets de millones de muestras



Fuente: umap-learn docs, Copyright (c) 2017 Leland McInnes, licencia BSD-3.

Resumen: 3.2 Reducción de dimensionalidad


- **PCA**: rápido, lineal, interpretable
- **Kernel PCA**: extiende PCA a estructuras no lineales
- ***t*-SNE**: visualización excelente, no lineal, lento en datos grandes
- **UMAP**: el mejor equilibrio entre velocidad y calidad

- *Inliers* (normales): frecuentes, con patrones consistentes
- *Outliers* (anomalías): raros, se desvían significativamente de la norma
- **Anomaly detection**: los datos de entrenamiento pueden contener ruido
- **Novelty detection**: los datos de entrenamiento están completamente limpios

Ejemplo: fraude bancario, fallos en una línea de producción, o un sensor que empieza a dar lecturas extrañas: en ninguno de estos casos sabemos de antemano cómo será la próxima anomalía.


Enfoque gaussiano

- Se ajusta una distribución gaussiana a los datos normales
- Los puntos con **baja densidad de probabilidad** se marcan como anomalías
- El umbral se puede fijar según la tasa histórica de casos raros conocida



Reconstrucción con PCA


- Se proyectan los datos a baja dimensión con PCA y se reconstruyen de vuelta
- Las anomalías no siguen la estructura principal, así que su **error de reconstrucción** es mucho mayor



Isolation Forest

- En vez de modelar lo normal, intenta **aíslar** cada punto con particiones aleatorias
- Las anomalías, al estar alejadas del resto, se aíslan con muy pocas particiones


Isolation Forest: intuición del aislamiento



Local Outlier Factor (LOF)


- Compara la **densidad local** de un punto con la de sus vecinos
- Detecta **anomalías locales**: puntos que no son extremos en términos absolutos, pero sí resultan raros en su vecindario

Ejemplo: una casa de 200 m² no es rara a nivel nacional, pero sí lo es en un barrio donde todas miden 60 m²: eso es exactamente lo que detecta LOF.



One-class SVM

- Diseñado para *novelty detection*: se entrena con datos limpios
- Encuentra la región de **volumen mínimo** que encierra casi todos los datos de entrenamiento
- Cualquier observación nueva fuera de esa frontera se marca como anomalía



- Las anomalías pueden ser eventos raros, contextuales o colectivos
- **Métodos simples:** gaussiana, reconstrucción con PCA
- **Métodos avanzados:** *Isolation Forest*, LOF, *one-class SVM*

1. Fundamentos

- Historia del ML
- *Overfitting/underfitting*
- Validación cruzada

2. Supervisado

- Regresión, regularización
- Clasificación, SVM
- Redes neuronales

3. No supervisado

- *Clustering*
- PCA, *manifold learning*
- Detección de anomalías

¡Gracias!

Universidad de Salamanca